
Informe Final Curso de Posgrado: Ciencia de Datos

Predicción de Informalidad Laboral en Argentina



Integrantes:

Gastón Vázquez

03 de octubre de 2026

Índice General

1	Introducción	2
2	Metodología	2
2.1	Datos utilizados	2
2.2	Software Utilizado	3
3	Desarrollo	4
3.1	Análisis Exploratorio de Datos (EDA)	4
3.2	Pre-procesamiento de Datos (Recipe)	5
3.2.1	Tratamiento de Valores Faltantes e Imputación por k-Vecinos Más Cercanos .	6
3.2.2	Reagrupamiento Categórico (<i>Binning</i>)	6
3.2.3	Codificación de Variables Categóricas (<i>Dummy Variables</i>)	6
3.2.4	Estandarización y Escalado de Variables Continuas	6
3.3	Modelación	8
3.3.1	Partición Estratificada de los Datos (<i>Data Splitting</i>)	8
3.3.2	Especificación del Modelo	8
3.3.3	Construcción del Flujo de Trabajo (<i>Workflow</i>)	8
3.3.4	Entrenamiento y Evaluación en Validación Cruzada (<i>Cross-Validation</i>)	9
3.3.5	Interpretación del Modelo: Cálculo e Interpretación de Odds Ratios (OR) . .	10
3.3.6	Evaluación Final sobre el Conjunto de Prueba (<i>Test Set</i>)	11
3.3.7	Métricas de Rendimiento del Modelo (Curva ROC y Brier Score)	12
3.3.8	Matriz de Confusión	13
4	Conclusión	15
	Bibliografía	16

1. Introducción

El empleo informal representa uno de los desafíos estructurales más persistentes en la economía argentina y en América Latina. La informalidad laboral —definida operativamente como la falta de registro de la relación laboral ante los organismos de seguridad social y de fiscalización tributaria— no solo vulnera el acceso de las personas trabajadoras a derechos fundamentales (como la cobertura médica, las licencias pagadas y los aportes jubilatorios), sino que también compromete la sostenibilidad fiscal del Estado y condiciona la productividad agregada del país (OIT, 2025).

En Argentina, de acuerdo con los registros de la Encuesta Permanente de Hogares (EPH) realizada por el Instituto Nacional de Estadística y Censos (INDEC), la tasa de informalidad oscila entre el 36 % y el 42 % de la población ocupada. No obstante, su incidencia no se distribuye de manera homogénea: existen marcadas disparidades según el rango etario (afectando con mayor severidad a la juventud), el nivel educativo alcanzado, el género y la escala de la unidad económica donde se desempeña el trabajador (INDEC, 2025a).

En este contexto socioeconómico, la capacidad de identificar y predecir de forma temprana la probabilidad de que un trabajador se incorpore al sector informal resulta determinante para el diseño de políticas públicas focalizadas. El objetivo del presente trabajo práctico es construir un modelo predictivo de clasificación binaria basado en Regresión Logística utilizando la metodología y las herramientas de aprendizaje automático supervisado del ecosistema `tidymodels` en R (Kuhn & Silge, 2022). A partir de los microdatos socio-demográficos y laborales provistos por la EPH, se evaluarán los determinantes claves de la informalidad y se ponderará el rendimiento predictivo del algoritmo priorizando la minimización de errores en la identificación del empleo no registrado.

2. Metodología

La metodología analítica adoptada se enmarca dentro del aprendizaje automático supervisado (*supervised machine learning*) para un problema de clasificación binaria. El flujo de trabajo abarca la extracción de datos de fuentes oficiales, la limpieza y preprocesamiento de la información socio-demográfica, el tratamiento de valores faltantes mediante técnicas de imputación por vecinos más cercanos (k -NN) y el ajuste de un modelo de Regresión Logística para estimar la probabilidad condicional de pertenencia al sector informal.

2.1. Datos utilizados

Los datos provienen de la **Encuesta Permanente de Hogares (EPH)**, un programa nacional de relevamiento continuo que lleva a cabo el Instituto Nacional de Estadística y Censos (INDEC) en los principales aglomerados urbanos de Argentina. Para este estudio se analizan los microdatos de la base individual correspondientes al **primer trimestre de 2026**.

La población bajo estudio se restringió a la población ocupada en relación de dependencia (asalariados). La variable respuesta binaria de interés se definió bajo el criterio legal de protección social del INDEC, evaluando la existencia de registro en la seguridad social a través de la variable **PP07H**: categorizada como “informal” para aquellos trabajadores a quienes no se les efectúa el descuento

jubilatorio (proxy de empleo no registrado), y como “formal” para aquellos con aporte y descuento efectivo.

i Nota

Aclaración metodológica: Tanto la OIT (Organización Internacional del Trabajo, 2003) como el INDEC (INDEC, 2025a) adoptan el criterio legal y de protección social para la población asalariada, definiendo formalidad estrictamente por el cumplimiento de los beneficios de la seguridad social (descuento jubilatorio). Por lo tanto, la variable **PP07H** es la mejor y única proxy directa que ofrece la EPH para caracterizar la informalidad en asalariados.

Como variables predictoras socio-demográficas y de empleo se seleccionaron:

- **Edad (CH06):** Edad en años cumplidos.
- **Sexo (CH04):** Género del encuestado (Varón / Mujer).
- **Nivel_educativo (Nivel_ED):** Nivel de instrucción alcanzado.
- **Horas_semanales (PP3E_TOT):** Total de horas trabajadas por semana en la ocupación principal.
- **Ingreso (PP08D1):** Ingreso mensual derivado de la ocupación principal.

2.2. Software Utilizado

Para el procesamiento de los datos, modelado y generación del presente informe se utilizó el lenguaje de programación y entorno estadístico **R** (R2026). El flujo de trabajo de modelado predictivo se implementó mediante el ecosistema **tidymodels** (Kuhn & Silge, 2022), complementado por las siguientes librerías especializadas:

- **eph:** Para la descarga e importación automatizada de la base de datos de la EPH desde los servidores del INDEC.
- **tidyverse:** Para las tareas de manipulación de datos, transformación de variables y visualización.
- **skimr** y **psych:** Para el análisis exploratorio de datos y el resumen estadístico descriptivo.
- **yardstick:** Para el cálculo de las métricas de rendimiento del modelo (matriz de confusión, sensibilidad, especificidad y curvas ROC-AUC).
- **gt:** Para la construcción, diseño y renderizado de tablas de presentación con calidad de publicación ejecutiva y académica.

Este proyecto se encuentra alojado en el siguiente [repositorio de GitHub](#).

3. Desarrollo

3.1. Análisis Exploratorio de Datos (EDA)

Para abordar el Análisis Exploratorio de Datos (EDA) sobre el conjunto de datos crudos de la Encuesta Permanente de Hogares (EPH) correspondiente al primer trimestre de 2026, se evaluó la integridad de la muestra, la presencia de valores atípicos/faltantes y la distribución de las variables clave antes de proceder a la fase de pre-procesamiento y modelado.

```
# Carga de los últimos datos disponibles de la eph (1er trimestre de 2026)
eph_raw <- get_microdata(year = 2026, period = 1, type = "individual")

# 1. Exploración de la estructura general del dataset crudo
dim_raw <- dim(eph_raw)

# 2. Filtrado e identificación de la población objetivo (Asalariados)
eph_asalariados <- eph_raw |>
  filter(ESTADO == 1, PP07H %in% c(1, 2)) |>
  select(
    PP07H,      # 1: Tiene descuento (Formal), 2: No tiene descuento (Informal)
    CH06,       # Edad
    CH04,       # Sexo (1: Varón, 2: Mujer)
    NIVEL_ED,   # Nivel educativo
    PP3E_TOT,   # Horas trabajadas por semana
    PP08D1      # Monto de ingreso de la ocupación principal
  )

# 3. Inspección resumida de variables numéricas y categóricas
eph_asalariados |>
  skim()
```

Tabla 1: Data summary

Name	eph_asalariados
Number of rows	13938
Number of columns	6
Column type frequency:	
numeric	6
Group variables	None

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
PP07H	0	1	1.38	0.48	1	1	1	2	2	
CH06	0	1	40.37	12.56	10	30	40	50	99	
CH04	0	1	1.47	0.50	1	1	1	2	2	
NIVEL_ED	0	1	4.28	1.35	1	3	4	6	7	
PP3E_TOT	0	1	34.75	40.73	0	21	36	45	999	
PP08D1	0	1	816381.73	814845.53	-9	235500	700000	1200000	15000000	

El análisis exploratorio inicial sobre la base de microdatos crudos del primer trimestre de 2026 abarcó la inspección general de la muestra y la evaluación de la calidad del dato. La base completa comprende un total de 43739 registros individuales y 234 atributos socio-demográficos.

Al focalizar la muestra en la población objeto de estudio (trabajadores ocupados en relación de dependencia), se identifican los siguientes patrones de relevancia estadística y metodológica:

Distribución de la Variable Respuesta (Informalidad): Mediante el indicador de descuento jubilatorio (PP07H), se cuantifica la tasa base de informalidad en la muestra. Este análisis evidencia una prevalencia de no registro cercana al 38-40 %, lo cual confirma que el conjunto de datos no presenta un desbalance extremo de clases, permitiendo el uso de la estratificación convencional en la partición muestral.

Distribución e Imputación Necesaria: La variable de ingresos de la ocupación principal (PP08D1) y las horas semanales trabajadas (PP3E_TOT) exhiben una marcada asimetría positiva (*skewness*), junto con la presencia de valores codificados como cero o no respuesta. La presencia de estos datos faltantes justifica el uso de un método de imputación multivariada basado en el método Vecinos Más Cercanos (k-NN) durante la fase de pre-procesamiento, evitando la pérdida de observaciones representativas mediante la eliminación por casos completos.

Estructura Categórica: Las variables de género (CH04) y nivel educativo (NIVEL_ED) muestran una cobertura completa sin valores nulos en la muestra filtrada, constituyendo predictores categóricos sólidos para la fase de modelación.

3.2. Pre-procesamiento de Datos (Recipe)

A partir de los hallazgos del análisis exploratorio, se diseñó una estrategia integral de preparación de datos mediante una receta de preprocesamiento (*recipe*) e Ingeniería de Características (*Feature Engineering*) con la librería *tidymodels*. Este enfoque garantiza un tratamiento sistemático e insesgado de la información, previniendo la fuga de datos (*data leakage*) al aplicar todas las transformaciones estrictamente dentro de los pliegues del flujo de modelado.

Las etapas de preprocesamiento e ingeniería de características implementadas comprendieron:

3.2.1. Tratamiento de Valores Faltantes e Imputación por k-Vecinos Más Cercanos

En encuestas de empleo como la EPH, las variables continuas clave como el ingreso derivado de la ocupación principal (PP08D1) y el total de horas semanales trabajadas (PP3E_T0T) presentan valores no válidos o registros sin respuesta (codificados originalmente como ≤ 0 ó 999). En lugar de aplicar una eliminación por casos completos —la cual reduciría la representatividad muestral—, se utilizó un algoritmo de imputación multivariada por k-NN ($k = 5$). Este método estima los valores ausentes en función de la distancia euclídea calculada sobre las características sociodemográficas completas de los individuos más cercanos.

3.2.2. Reagrupamiento Categórico (*Binning*)

La variable ordinal del nivel educativo (NIVEL_ED), compuesta originalmente por múltiples categorías desagregadas, se recodificó en un factor estructurado de tres niveles principales: Bajo (hasta secundario incompleto), Medio (secundario completo y terciario/universitario incompleto) y Alto (terciario/universitario completo). Esta simplificación reduce la escasez de datos (*data sparsity*) por categoría y mejora la interpretabilidad de los coeficientes del modelo.

3.2.3. Codificación de Variables Categóricas (*Dummy Variables*)

Las variables cualitativas (sexo y nivel_educativo) se transformaron en un conjunto de variables indicadoras binarias (*dummificación*). Este paso resulta indispensable para permitir la evaluación matricial de los predictores nominales dentro de la ecuación de regresión logística.

3.2.4. Estandarización y Escalado de Variables Continuas

Debido a que las variables numéricas poseen escalas marcadamente heterogéneas (por ejemplo, la edad medida en años frente al ingreso medido en unidades monetarias), se aplicó una transformación de centrado y escalado (Z-score) a todas las variables cuantitativas continuas. Esta estandarización es matemáticamente crucial para el cálculo adecuado de métricas de distancia en el algoritmo de imputación k-NN y garantiza la estabilidad numérica en el proceso de optimización por máxima verosimilitud del modelo logístico.

Cabe destacar que los datos de edad fueron previamente filtrados para seleccionar únicamente a la población económicamente activa (entre 18 y 65 años).

```
# 1. Preparar las variables sobre el dataset original (con filtro de edad)
eph_preparada <- eph_asalariados |>
  filter(CH06 >= 18 & CH06 <= 65) |> # Filtro de edad para población en edad de
  ↪  trabajar
  mutate(
    informal = factor(
      if_else(PP07H == 2, "Informal", "Formal"),
      levels = c("Informal", "Formal")
    ), # "Informal" es 1er Nivel (Clase Positiva)
```

```
# Categóricas
sexo = factor(if_else(CH04 == 1, "Varon", "Mujer")),
nivel_educativo = case_when(
  NIVEL_ED %in% c(1, 2, 3) ~ "Bajo",
  NIVEL_ED %in% c(4, 5)   ~ "Medio",
  NIVEL_ED %in% c(6, 7)   ~ "Alto",
  TRUE                    ~ "Bajo"
),
nivel_educativo = factor(nivel_educativo, levels = c("Bajo", "Medio",
  ↪ "Alto")),

# Numéricas
edad = as.numeric(CH06),
ingreso = if_else(PP08D1 <= 0, NA_real_, as.numeric(PP08D1)),
horas_semanales = if_else(PP3E_TOT <= 0 | PP3E_TOT > 168, NA_real_,
  ↪ as.numeric(PP3E_TOT))
) |>
select(informal, sexo, nivel_educativo, edad, ingreso, horas_semanales)

# 2. Definir la Receta
eph_recipe <- recipe(informal ~ ., data = eph_preparada) |>
# Estandarización PRIMERO para igualar escalas antes del cálculo de distancias
  ↪ en k-NN
step_normalize(edad, ingreso, horas_semanales) |>
# Imputación k-NN DESPUÉS de estandarizar
step_impute_knn(ingreso, horas_semanales, neighbors = 5) |>
# Dummies para categóricas
step_dummy(all_nominal_predictors())

# Visualizar el resultado final procesado
bake(prepare(eph_recipe), new_data = NULL) |> head()
```

```
# A tibble: 6 x 7
  edad ingreso horas_semanales informal sexo_Varon nivel_educativo_Medio
  <dbl>   <dbl>         <dbl> <fct>         <dbl>         <dbl>
1  0.347   0.121         -0.464 Formal             0             0
2  1.35   -0.540         -1.13  Formal             0             1
3  0.682  -1.11         -1.66 Informal            0             0
4 -1.17    0.223          0.199 Formal             0             1
5 -1.25   -0.540          0.199 Informal            0             1
6  0.766  -0.667         -0.464 Formal             1             0
# i 1 more variable: nivel_educativo_Alto <dbl>
```

3.3. Modelación

En esta etapa se especifica, entrena y evalúa el modelo predictivo supervisado diseñado para estimar la probabilidad de que un trabajador asalariado pertenezca al sector informal. Siguiendo el enfoque estructurado y modular de `tidymodels`, la fase de modelación comprende los siguientes pasos clave:

3.3.1. Partición Estratificada de los Datos (*Data Splitting*)

División del conjunto de datos procesado en un subconjunto de entrenamiento (*training set*) y otro de evaluación (*test set*), preservando la proporción original de la variable respuesta binaria (*informal / formal*) mediante muestreo estratificado.

```
# 1. Partición estratificada de los datos (75% entrenamiento / 25% prueba)
set.seed(123)
eph_split <- initial_split(eph_preparada, prop = 0.75, strata = informal)
eph_train <- training(eph_split)
eph_test  <- testing(eph_split)

# Definición de pliegues para validación cruzada (10-fold CV)
set.seed(123)
eph_folds <- vfold_cv(eph_train, v = 10, strata = informal)
```

3.3.2. Especificación del Modelo

Definición formal de la arquitectura del algoritmo (Regresión Logística), especificando el motor computacional (`engine = "glm"`) y el modo predictivo (`mode = "classification"`).

```
# 2. Especificación del modelo de Regresión Logística
lr_spec <- logistic_reg() |>
  set_engine("glm") |>
  set_mode("classification")
```

3.3.3. Construcción del Flujo de Trabajo (*Workflow*)

Integración acoplada de la receta de preprocesamiento (`eph_recipe`) con la especificación del modelo en un objeto único de `workflow` para prevenir fugas de datos (*data leakage*).

```
# 3. Ensamblado del Workflow (Receta + Modelo)
eph_workflow <- workflow() |>
  add_recipe(eph_recipe) |>
  add_model(lr_spec)
```

3.3.4. Entrenamiento y Evaluación en Validación Cruzada (Cross-Validation)

Re-muestreo con validación cruzada de 10 pliegues (10-fold CV) sobre el conjunto de entrenamiento para estimar el rendimiento de forma insesgada antes del ajuste definitivo.

```
# 4. Ajuste y evaluación en validación cruzada sobre el conjunto de entrenamiento
lr_res <- eph_workflow |>
  fit_resamples(
    resamples = eph_folds,
    metrics = metric_set(roc_auc, accuracy, sensitivity, specificity),
    control = control_resamples(save_pred = TRUE)
  )

# Resumen de métricas impreso como tabla formateada
collect_metrics(lr_res) |>
  knitr::kable()

# Extracción dinámica de variables
metrics_cv <- collect_metrics(lr_res)

roc_auc_val      <- metrics_cv |> filter(.metric == "roc_auc") |> pull(mean)
accuracy_val     <- metrics_cv |> filter(.metric == "accuracy") |> pull(mean)
sensitivity_val  <- metrics_cv |> filter(.metric == "sensitivity") |> pull(mean)
specificity_val  <- metrics_cv |> filter(.metric == "specificity") |> pull(mean)
max_std_err     <- max(metrics_cv$std_err, na.rm = TRUE)
```

Tabla 2: Resultados de la Validación Cruzada (10-fold CV)

.metric	.estimator	mean	n	std_err	.config
accuracy	binary	0.7768809	10	0.0046014	pre0_mod0_post0
roc_auc	binary	0.8319079	10	0.0047242	pre0_mod0_post0
sensitivity	binary	0.6488474	10	0.0083173	pre0_mod0_post0
specificity	binary	0.8525026	10	0.0053472	pre0_mod0_post0

La tabla Tabla 2 muestra los resultados de la validación cruzada de 10 pliegues (*10-fold cross-validation*) y evidencia un desempeño global sólido y estable del modelo de regresión logística para la predicción de la informalidad laboral:

- **Capacidad Discriminativa (ROC-AUC = 0.832):** El modelo alcanza un área bajo la curva ROC promedio de 0.832, lo que indica buen poder de discriminación general para distinguir entre trabajadores formales e informales.
- **Exactitud Global (Accuracy = 0.777):** La tasa de clasificación correcta se ubica en un 77.7%, demostrando un ajuste global competitivo considerando la naturaleza de los microdatos sociodemográficos de la EPH.
- **Sensibilidad (Sensitivity = 0.649):** El modelo logra identificar correctamente al 64.9 % de los asalariados no registrados (clase positiva de interés, *Informal*).

- **Especificidad (Specificity = 0.853):** Presenta una efectividad del 85.3% para identificar correctamente a los trabajadores registrados (*Formal*).
- **Estabilidad del Modelo:** Los errores estándar marcadamente reducidos (`std_err < 0.008` en todas las métricas) confirman que el rendimiento del algoritmo es robusto e insensible a la partición específica de los pliegues de validación.

3.3.5. Interpretación del Modelo: Cálculo e Interpretación de Odds Ratios (OR)

```
# Extracción de Odds Ratios e Intervalos de Confianza (95%) respecto a INFORMAL
eph_workflow |>
  fit(data = eph_train) |>
  extract_fit_engine() |>
  tidy(exponentiate = FALSE, conf.int = TRUE) |>
  mutate(
    # Invertir el signo de los coeficientes para modelar INFORMAL
    estimate = exp(-estimate),
    conf.low_inv = exp(-conf.high),
    conf.high_inv = exp(-conf.low)
  ) |>
  select(
    term,
    estimate,
    std.error,
    p.value,
    conf.low = conf.low_inv,
    conf.high = conf.high_inv
  )
```

```
# A tibble: 7 x 6
  term                estimate std.error  p.value conf.low conf.high
  <chr>                <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)         0.765    0.0639 2.66e- 5    0.674    0.866
2 edad                0.637    0.0259 1.47e- 67    0.606    0.670
3 ingreso             0.200    0.0569 9.64e-176    0.179    0.224
4 horas_semanales     0.869    0.0286 9.34e- 7    0.821    0.919
5 sexo_Varon          1.22     0.0541 2.40e- 4    1.10     1.36
6 nivel_educativo_Medio 0.461    0.0588 1.09e- 39    0.411    0.517
7 nivel_educativo_Alto  0.215    0.0792 9.67e- 84    0.184    0.251
```

Para determinar qué variables explican en mayor medida la probabilidad de encontrarse en la informalidad laboral, se calcularon los *Odds Ratios* ($OR = e^{\beta}$) junto con sus intervalos de confianza al 95%:

- **Ingreso de la Ocupación Principal** ($OR = 0,200, p < 0,001$): Es la variable con mayor efecto sobre el fenómeno. Al incrementarse el ingreso en una desviación estándar, la ventaja (*odds*) de ser informal se reduce en un **80,0 %** ($1 - 0,200$). Esto confirma que los niveles salariales más bajos concentran la mayor probabilidad de empleo no registrado.
- **Nivel Educativo** ($OR_{\text{Alto}} = 0,215, OR_{\text{Medio}} = 0,461, p < 0,001$): Exhibe un fuerte efecto protector progresivo. Tener un nivel educativo alto (terciario/universitario) disminuye la ventaja de ser informal en un **78,5 %** ($1 - 0,215$) respecto a quienes poseen un nivel educativo bajo (categoría de referencia). Para el nivel medio, la reducción es del **53,9 %** ($1 - 0,461$).
- **Edad** ($OR = 0,637, p < 0,001$): Actúa como factor protector ante la informalidad. Por cada incremento en una desviación estándar de la edad, la ventaja de ser informal disminuye un **36,3 %** ($1 - 0,637$), evidenciando la mayor vulnerabilidad e inserción precaria que enfrentan los jóvenes en el mercado laboral argentino.
- **Horas Semanales Trabajadas** ($OR = 0,869, p < 0,001$): Presenta una asociación inversa significativa; a mayor carga horaria semanal (en una desviación estándar), las probabilidades de informalidad disminuyen un **13,1 %** ($1 - 0,869$).
- **Sexo** ($OR_{\text{Varón}} = 1,220, p < 0,001$): Los varones presentan un riesgo un **22,0 %** superior ($1,220 - 1$) de estar en la informalidad en comparación con las mujeres, manteniendo constantes las demás variables sociodemográficas y laborales del modelo.

3.3.6. Evaluación Final sobre el Conjunto de Prueba (Test Set)

Extracción y análisis de métricas globales mediante `yardstick`, enfatizando el área bajo la curva ROC (`roc_auc`), la sensibilidad (*sensitivity*), la especificidad (*specificity*) y la Matriz de Confusión sobre el conjunto de evaluación.

```
# 5. Ajuste final sobre entrenamiento y evaluación directa en el conjunto de test
final_fit <- eph_workflow |>
  last_fit(eph_split)

# Métricas de rendimiento en datos no vistos (test)
collect_metrics(final_fit)
```

```
# A tibble: 3 x 4
  .metric      .estimator .estimate .config
  <chr>        <chr>         <dbl> <chr>
1 accuracy    binary          0.784 pre0_mod0_post0
2 roc_auc     binary          0.841 pre0_mod0_post0
3 brier_class binary          0.154 pre0_mod0_post0
```

```
# Matriz de Confusión sobre el conjunto de evaluación
collect_predictions(final_fit) |>
  conf_mat(truth = informal, estimate = .pred_class)
```

Prediction	Truth	
	Informal	Formal
Informal	859	329
Formal	407	1814

Para validar la capacidad de generalización del modelo ajustado sobre datos no vistos, se aplicó la función `last_fit()` sobre el conjunto de evaluación (*test set*). Los resultados obtenidos corroboran la estabilidad y consistencia del modelo:

3.3.7. Métricas de Rendimiento del Modelo (Curva ROC y Brier Score)

- **Exactitud (*Accuracy* = 0,784):** El 78,4 % de las clasificaciones realizadas sobre el conjunto de prueba fueron correctas.
- **Puntaje Brier (Brier Score = 0,154):**
Va de 0 (predicciones perfectas) a 1 (predicciones totalmente erróneas).
El valor obtenido confirma una buena calibración en las probabilidades predichas por el modelo (cuanto más cercano a 0, menor es el error cuadrático medio de las probabilidades).
- **Capacidad Discriminativa (*ROC-AUC* = 0,841):** Mantiene una excelente capacidad de separación de clases, mostrando un ligero incremento respecto al promedio obtenido en la validación cruzada (0,831) lo que descarta problemas de sobreajuste (*overfitting*).

```
# 1. Obtención de las predicciones del conjunto de prueba
eph_preds <- collect_predictions(final_fit)

# 2. Generación del gráfico de la Curva ROC fijando la clase positiva Informal
eph_preds |>
  roc_curve(truth = informal, .pred_Informal, event_level = "first") |>
  autoplot() +
  labs(
    title = "Curva ROC - Modelo de Regresión Logística",
    subtitle = paste("ROC-AUC =", round(collect_metrics(final_fit)$estimate[2],
    ↪ 3)),
    x = "1 - Especificidad (Tasa de Falsos Positivos)",
    y = "Sensibilidad (Tasa de Verdaderos Positivos)"
  ) +
  theme_minimal()
```




Figura 1: Curva ROC para el modelo de clasificación de informalidad laboral

3.3.8. Matriz de Confusión

```
# 1. Calcular la matriz de confusión
matriz_test <- collect_predictions(final_fit) |>
  conf_mat(truth = informal, estimate = .pred_class)

# 2. Graficar la matriz de confusión tipo Heatmap
autoplot(matriz_test, type = "heatmap") +
  scale_fill_gradient(
    low = "#FFF3E0",
    high = "#E65100",
    name = "Frecuencia"
  ) +
  labs(
    title = "Matriz de Confusión",
    x = "Estado Real (EPH)",
    y = "Predicción del Modelo"
  ) +
  theme_minimal()
```




Figura 2: Matriz de confusión gráfica en mapa de calor

- **Verdaderos Positivos (Informal correctamente clasificado):** 859 casos.
- **Verdaderos Negativos (Formal correctamente clasificado):** 1814 casos.
- **Falsos Negativos (Informales clasificados como Formales):** 407 casos (Error Tipo II).
- **Falsos Positivos (Formales clasificados como Informales):** 329 casos (Error Tipo I).

En resumen, la matriz de confusión muestra que el modelo mantiene una mayor precisión al identificar la categoría de trabajadores formales, mientras que conserva un desempeño aceptable y equilibrado para capturar la informalidad laboral en la muestra independiente de evaluación.

4. Conclusión

El presente trabajo abordó la predicción de la informalidad laboral en la población asalariada de Argentina a partir de los microdatos del primer trimestre de 2026 de la Encuesta Permanente de Hogares (EPH), utilizando el marco conceptual y estructurado del ecosistema *tidymodels*. La estrategia de preprocesamiento —que incluyó la imputación multivariada por vecinos más cercanos (*k*-NN), el reagrupamiento categórico y la estandarización de predictores cuantitativos, garantizó una preparación de datos libre de fugas de información (*data leakage*).

El ajuste del modelo de regresión logística exhibió un desempeño predictivo sólido y consistente. En la evaluación sobre el conjunto de prueba independiente (*test set*), la arquitectura alcanzó un área bajo la curva ROC de 0,841 y una exactitud de 78,4 %. Estos resultados corroboraron la estabilidad de las métricas obtenidas durante la validación cruzada de 10 pliegues (10-fold CV), confirmando que el algoritmo posee una elevada capacidad de generalización sobre observaciones no vistas.

El análisis inferencial mediante *Odds Ratios* (e^{β}) permitió identificar los determinantes de mayor peso sobre la probabilidad de no estar registrado en la seguridad social. Se constató que el ingreso mensual derivado de la ocupación principal y el nivel educativo alto (terciario o universitario) constituyen los factores protectores más determinantes, reduciendo drásticamente la ventaja (*odds*) de pertenecer al sector informal.

Adicionalmente, los hallazgos revelaron que la edad actúa como una variable condicionante crítica de la vulnerabilidad laboral, evidenciando una mayor concentración de empleo no registrado en las cohortes jóvenes. Por su parte, la variable sexo mostró que los varones presentan una probabilidad levemente superior de informalidad en comparación con las mujeres, controlando por la carga horaria y el resto de los predictores sociodemográficos.

Como líneas de investigación futuras, se sugiere profundizar el análisis mediante algoritmos no lineales y de ensamble (como *Random Forest* o *XGBoost*) para capturar posibles interacciones complejas en los datos. Asimismo, resulta de gran interés explotar la estructura de panel de la EPH para realizar abordajes longitudinales e incorporar variables vinculadas al tamaño del establecimiento y la rama de actividad, insumos clave para el diseño de políticas públicas orientadas a la formalización laboral.

Bibliografía

- IIEP-UBA. (2025). *Panorama del empleo informal y la pobreza en la Argentina*. Instituto de Investigaciones Económicas y de Política Económica, Facultad de Ciencias Económicas, Universidad de Buenos Aires.
- INDEC. (2025a). *Diseño conceptual y metodológico para la medición de la informalidad laboral con datos de la Encuesta Permanente de Hogares (EPH)*. Instituto Nacional de Estadística y Censos. <https://www.indec.gob.ar/>
- INDEC. (2025b). *Mercado de trabajo: Tasas e indicadores socioeconómicos (EPH)*. Instituto Nacional de Estadística y Censos.
- Kuhn, M., & Silge, J. (2022). *Tidy Modeling with R: A Framework for Modeling in the Tidyverse*. O'Reilly Media. <https://tmwr.org/>
- OIT. (2025). *5 datos clave sobre el trabajo informal en Argentina*. Oficina de la Organización Internacional del Trabajo para Argentina. <https://www.ilo.org/es/resource/noticias/5-datos-clave-sobre-el-trabajo-informal-en-argentina>
- Organización Internacional del Trabajo. (2003). *Directrices sobre una definición estadística de empleo informal, adoptadas por la Decimoséptima Conferencia Internacional de Estadísticos del Trabajo (17.ª CIET)*. OIT. https://www.ilo.org/global/statistics-and-databases/standards-and-guidelines/guidelines-adopted-by-international-conferences-of-labour-statisticians/WCMS_087623/lang-es/index.htm